

PROYECTO: MODERN DATA STACK FOR AN OLIVE OIL COOPERATIVE

1. CONTEXTO Y JUSTIFICACIÓN

Una cooperativa olivarera gestiona información crítica relacionada con:

- Socios
- Parcelas
- Entregas de aceituna
- Procesos de molturación
- Calidad del aceite
- Liquidaciones y pagos
- Ventas

Actualmente los datos están dispersos en múltiples fuentes (Excel, ERP, sistemas internos), lo que impide una visión unificada y fiable para la toma de decisiones.

El objetivo del proyecto es diseñar y construir un Data Warehouse moderno que permita centralizar, transformar y analizar la información de forma estructurada y profesional.

2. OBJETIVO DEL PROYECTO

Construir una plataforma analítica end-to-end que incluya:

- Generación de datos sintéticos realistas
 - Ingesta de datos en una base PostgreSQL
 - Transformaciones mediante dbt
 - Modelo estrella (dimensiones + hechos)
 - Tests de calidad de datos
 - Orquestación del pipeline con Airflow
 - Entorno reproducible mediante Docker
 - Documentación profesional lista para GitHub
-

3. PROBLEMAS DE NEGOCIO A RESOLVER

El sistema debe permitir responder preguntas como:

- ¿Cuántos kg entrega cada socio por campaña?
- ¿Qué parcelas tienen mejor rendimiento graso?
- ¿Cómo influye la calidad en el pago final?
- ¿Cómo evoluciona la producción entre campañas?

- ¿Qué socios son más rentables?
-

4. ARQUITECTURA GENERAL

Infraestructura: - Docker Compose - PostgreSQL (base de datos) - Airflow (orquestación) - dbt (transformaciones) - Python (generación e ingesta)

Capas del Data Warehouse:

- 1) RAW Datos tal cual llegan al sistema.
 - 2) STAGING Datos limpios, tipados y normalizados.
 - 3) MARTS Modelo estrella listo para análisis.
-

5. MODELO DE DATOS PROPUESTO

Dimensiones

- dim_date
- dim_campaign
- dim_member
- dim_plot
- dim_quality_grade
- dim_product (opcional)
- dim_customer (opcional)

Tablas de hechos

- fact_deliveries Grano: 1 fila = 1 entrega de aceituna
 - fact_milling_batches Grano: 1 fila = 1 lote de molturación
 - fact_settlements Grano: 1 fila = 1 liquidación por socio y campaña
 - fact_sales (opcional) Grano: 1 fila = 1 línea de venta
-

6. GENERACIÓN DE DATOS SINTÉTICOS

El proyecto utilizará datos generados artificialmente con reglas realistas:

- 3 a 5 campañas agrícolas
- 200 a 500 socios

- 800 a 2.000 parcelas
- Hasta varios millones de entregas
- Estacionalidad (pico en noviembre-diciembre)
- Rendimiento correlacionado con variedad
- Penalizaciones por humedad o impurezas

El generador deberá:

- Permitir configuración de escala
 - Permitir semilla (seed) para reproducibilidad
-

7. PIPELINE DE DATOS

Secuencia de ejecución:

1) Generación de datos 2) Carga a esquema RAW 3) Transformaciones dbt (staging) 4) Construcción modelo estrella (marts) 5) Tests de calidad

Orquestado mediante Airflow.

8. HERRAMIENTAS Y SU FUNCIÓN

PostgreSQL: Base de datos relacional que almacena todas las capas.

Python: Generación de datos e ingesta.

DBT: Transformaciones SQL versionadas y testeadas.

Airflow: Automatización y orquestación del pipeline.

Docker: Entorno reproducible que permite levantar todo con un solo comando.

Metabase (opcional): Visualización y dashboards.

9. PLAN DE TRABAJO POR ETAPAS

Milestone 0 – Entorno

- Configuración de Docker
- PostgreSQL funcionando
- Estructura inicial del repositorio

Milestone 1 – Datos RAW

- Generador de datos
- Carga en esquema raw
- Registro de ingestas

Milestone 2 – STAGING

- Modelos stg_*
- Limpieza y normalización
- Tests básicos

Milestone 3 – MARTS

- Dimensiones
- Tablas de hechos
- KPIs calculados

Milestone 4 – Orquestación

- DAG en Airflow
- Automatización completa

Milestone 5 – Documentación y presentación

- README profesional
- Diagrama de arquitectura
- Diagrama modelo estrella

10. ESTRUCTURA DEL REPOSITORIO

olive-coop-dwh/ docker/ airflow/ dbt/ src/ data/ docs/ .env.example .gitignore Makefile README.md

11. MÉTRICAS DE ÉXITO

- Pipeline reproducible con Docker
 - Modelo estrella documentado
 - Tests de calidad pasando
 - Cargas incrementales implementadas
 - KPIs disponibles para análisis
 - Documentación clara y profesional
-

12. BUENAS PRÁCTICAS

- Versionado con Git
 - Uso de ramas feature/*
 - Commits semánticos (feat:, test:, docs:)
 - No subir datos grandes ni credenciales
 - Uso de .env para configuración
-

13. FUTURAS MEJORAS

- Integración con datos climáticos reales
 - Particionado por campaña
 - Snapshots SCD2
 - CI/CD con GitHub Actions
 - Benchmark de rendimiento
-

14. RESULTADO FINAL ESPERADO

Un proyecto profesional que simule un entorno real de empresa agrícola y demuestre competencias en:

- Modelado dimensional
- SQL avanzado
- Transformaciones con dbt
- Orquestación con Airflow
- Infraestructura reproducible con Docker
- Documentación técnica profesional

Este proyecto está diseñado para servir como pieza central de un portfolio orientado a roles de Data Engineer.